

Instituto Tecnológico y de Estudios Superiores de Monterrey

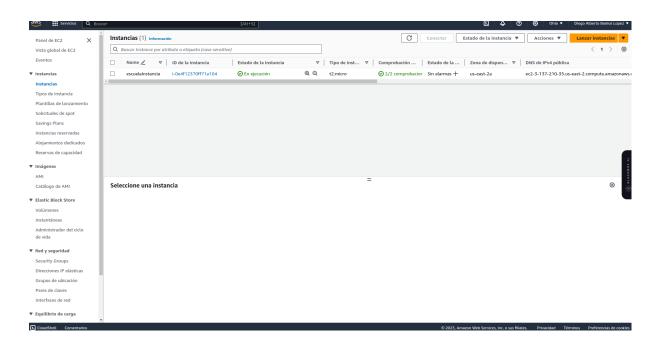
AWS E2C y Sparks

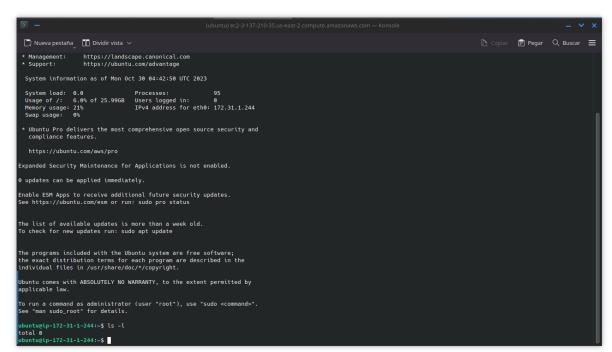
Diego Alberto Baños Lopez

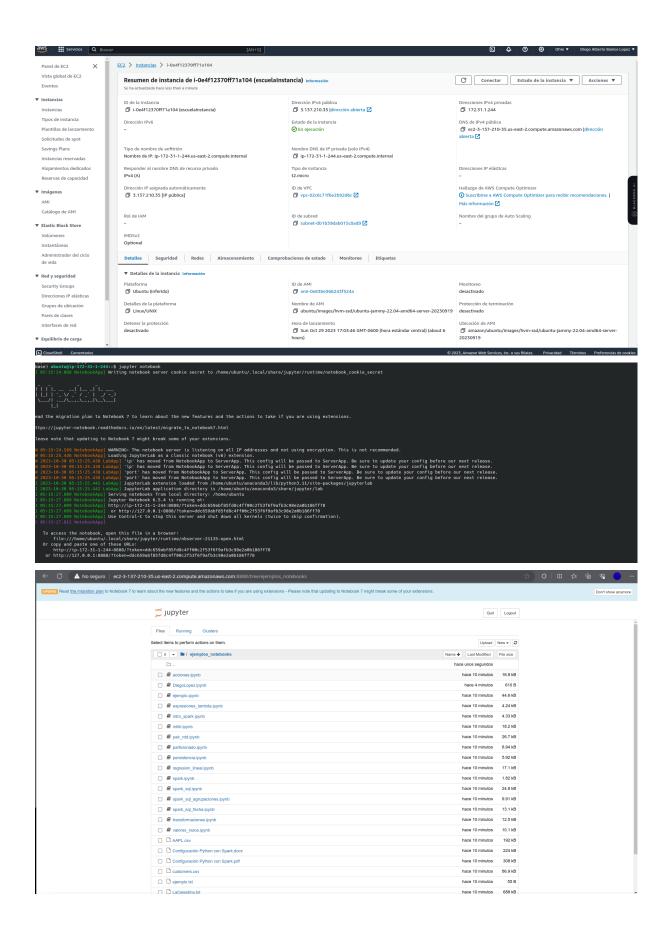
A01275100

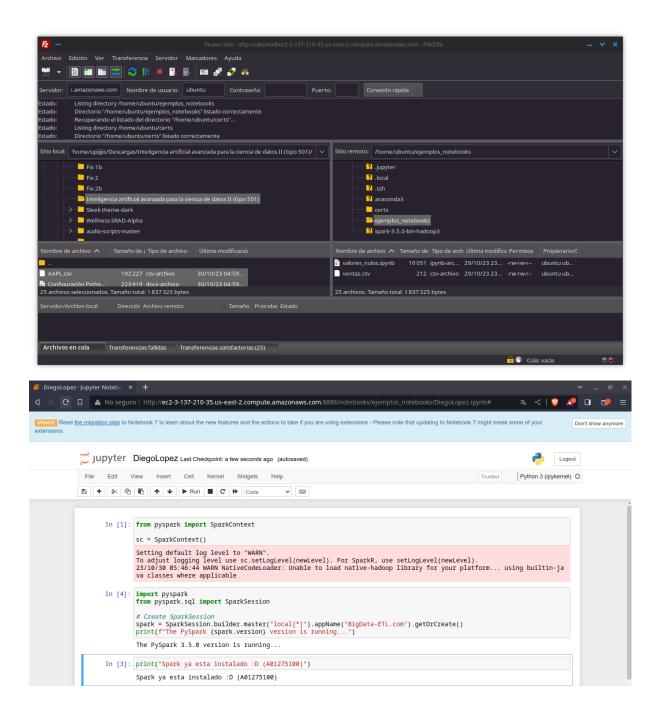
Monterrey, Nuevo León, México 29 de Octubre del 2023

Inteligencia artificial avanzada para la ciencia de datos II (Gpo 501)









```
In [4]: spark = SparkSession.builder.appName('DataFrame').getOrCreate()
         23/11/25 20:19:59 WARN SparkSession: Using an existing Spark session; only runtime SQL configurations will take effect.
In [5]: df = spark.read.csv('ventas.csv', inferSchema = True, header = True)
In [6]: df.show()
         |Empresa|Persona|Ventas|
              G00G| Carlos|
G00G| Juan|
                                200 |
120 |
             GOUG| Juan|
GOOG| Felipe|
MSFT| Tire'
                                340
600
              MSFT| Andrea|
                                124
             MSFT| Carla|
FB| Sara|
                                243 i
                                870
              FB|Ignacio|
APPL| Miguel|
                                350 i
                                250
             APPL| Oscar|
APPL| Jorge|
APPL| Ivan|
                                130
                               350 i
In [7]: df.groupBy('Empresa').sum().show()
                                                                                        (0 + 1) / 1]
         [Stage 3:>
         |Empresa|sum(Ventas)|
              APPL |
GOOG |
                           1480
660
             FB|
MSFT|
                          1220
                            967
             т-----
   In [8]: df.agg({'Ventas': 'max'}).show()
             |max(Ventas)|
             | 870|
| ----
   In [9]: agrupado = df.groupBy('Empresa')
agrupado.agg({'Ventas': 'max'}).show()
             +----+
|Empresa|max(Ventas)|
                 APPL| 750|
                 GOOG
                                340
870
                  FB
                 MSFT
                                600
  In [10]: agrupado.agg({'Ventas': 'min'}).show()
             |Empresa|min(Ventas)|
                 GOOG
                                120 i
                 MSFT
                               124
```

```
In [11]: df_agrupado = agrupado.agg({'Ventas': 'max'})
    df_agrupado_pandas = df_agrupado.toPandas()

In [15]: df_agrupado_pandas = df_agrupado_pandas.sort_values('max(Ventas)', ascending=False)
    import matplotlib.pyplot as plt

plt.figure(figsize=(10,6))
    plt.bar(df_agrupado_pandas['Empresa'], df_agrupado_pandas['max(Ventas)'])
    plt.xlabel('Empresa')
    plt.ylabel('Maximo de Ventas')
    plt.title('Máximo de Ventas por Empresa')
    plt.xticks(rotation=45) # Rotar las etiquetas si son muchas o largas
    plt.show()
```

